



Technik Autonomer Systeme: Bayes

Dirk Wollherr

*Lehrstuhl für Steuerungs- und Regelungstechnik
Technische Universität München*

Problembeschreibung

Localization:

- Bestimmung der eigenen Position und Orientierung in einer physikalischen Umgebung

Mapping:

- Erstellung einer Karte der physikalischen Umgebung
- geeignete Wahl der Metrik

Exploration:

- Erkundung einer unbekannten Umgebung
- gleichzeitiger Aufbau einer Karte und Bestimmung der eigenen Position

Navigation:

- Planung eines Pfads von der aktuellen Position zu einem Ziel

Lokalisierung (Localization)

Problemstellung:

- Bestimmung der eigenen Position und Orientierung in einer physikalischen Umgebung

Voraussetzungen:

- Umgebung bekannt
- Karte existiert
- Roboter verfügt über Sensoren zur Positionsbestimmung


Schwierigkeiten/Anforderungen:

- Sensorsignale sind fehlerhaft bzw. verrauscht
- erforderliche Genauigkeit der Daten
- erforderliche Datenrate

TAS - SLAM

Folie 3

Klassifikation der Sensoren zur Lokalisierung



TAS - SLAM

Folie 4

Klassische Architektur

Positionsbestimmung:


- Position im Raum
- Orientierung

Odometry

IMU

Sensorsysteme:

- Odometrie
- Gyrometer/IMU
- absolutes Trackingsystem
(GPS/Landmarken)



Sensorfusion:

- Vorteile kombinieren → Gesamtleistung höher als die Leistung einzelner Sensoren
- Kalman Filter


TAS - SLAM

Folie 5

Stochastische Methoden

Einsatz zur Lokalisierung/Kartenerstellung:

- stochastische (wahrscheinlichkeitstheoretische) Methoden weit verbreitet
- Nutzdaten von Sensoren sind mit Rauschen überlagert
- Rauschen kann als Zufallsprozess modelliert werden
- Positionsbestimmung (Roboter und Objekte) unterliegt Unsicherheiten



Stochastische Methoden und Modelle:

- Satz von Bayes
- Kalman Filter
- Markov Modelle

TAS - SLAM

Folie 6

Diskrete Zufallsvariablen

- X bezeichnet eine Zufallsvariable.
- X kann eine abzählbare Anzahl von Werten $\{x_1, x_2, \dots, x_n\}$ annehmen.
- $P(X=x_i)$ oder $P(x_i)$, ist die Wahrscheinlichkeit, dass Zufallsvariable X den Wert x_i annimmt.
- $P(X)$ heisst Wahrscheinlichkeitsfunktion.
- Z.B. $P(Room) = 0.7$ (oder 0.2 oder 0.08 ...)

TAS - SLAM


Folie 7

Kontinuierliche Zufallsvariablen

- X nimmt kontinuierliche Werte an.
- $p(X=x)$, oder $p(x)$, ist eine Wahrscheinlichkeitsdichtefunktion.

$$P(x \in (a, b)) = \int_a^b p(x) dx$$

- Z.B.



TAS - SLAM

Folie 8

Gemeinsame und bedingte Wahrscheinlichkeit

- $P(X=x \text{ und } Y=y) = P(x,y)$
- Wenn X und Y unabhängig sind:
$$P(x,y) = P(x) P(y)$$
- $P(x | y)$ ist die Wahrscheinlichkeit für x unter Voraussetzung y
$$P(x | y) = P(x,y) / P(y)$$

$$P(x,y) = P(x | y) P(y)$$
- Wenn X und Y unabhängig sind
$$P(x | y) = P(x)$$

TAS - SLAM


Folie 9

Gaussians

Univariate

$$p(x) \sim N(\mu, \sigma^2) :$$


$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$




Multivariate

$$p(\mathbf{x}) \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) :$$

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} e^{-\frac{1}{2} (\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}$$




Mathematischer Einschub: Zufallsvariablen



TAS - SLAM

Folie 11


Mathematischer Einschub: Zufallsvariablen



TAS - SLAM

Folie 12


Mathematischer Einschub: Zufallsvariablen



TAS - SLAM

Folie 13


Mathematischer Einschub: Zufallsvariablen



TAS - SLAM

Folie 14

Mathematischer Einschub: Zufallsvariablen



TAS - SLAM

Folie 15

Satz von Bayes (Bayes' Rule)

Allgemein:

- Umkehren von Schlussfolgerungen (Ereignis – Ursache)
- *Thomas Bayes, englischer Mathematiker (1702 – 1761)*



Theorem:


$$P(x|y) = \frac{P(y|x)P(x)}{P(y)} = \frac{\text{likelihood} \cdot \text{prior}}{\text{evidence}}$$

- $P(x|y)$: Wahrscheinlichkeit für das Ereignis x unter der Vorbedingung y
- $P(y|x)$: Wahrscheinlichkeit für das Ereignis y unter der Vorbedingung x
- $P(x)$: A priori Wahrscheinlichkeit für das Ereignis x

TAS - SLAM

Folie 16

Markov Annahme




Zugrundeliegende Annahmen

- Statische Welt
- Unabhängiges Rauschen
- Perfektes Modell, keine Annäherungsfehler

Einfaches Beispiel

- Roboter erhält Messung z
- Wie ist $P(open|z)$



Beispiel

$$\begin{aligned}P(z|open) &= 0.6 & P(z|\neg open) &= 0.3 \\P(open) &= P(\neg open) = 0.5\end{aligned}$$

$$P(open|z) = \frac{P(z|open)P(open)}{P(z|open)P(open) + P(z|\neg open)P(\neg open)}$$

$$P(open|z) = \frac{0.6 \cdot 0.5}{0.6 \cdot 0.5 + 0.3 \cdot 0.5} = \frac{2}{3} = 0.67$$

Beobachtung z erhöht die Wahrscheinlichkeit, dass die Tür offen ist.

TAS - SLAM

Folie 19

Hintergrundwissen

➤ Bayes rule und Hintergrundwissen

$$P(x|y, z) = \frac{P(y|x, z)P(x|z)}{P(y|z)}$$

➤ Unabhängigkeit


$$P(x, y|z) = P(x|z)P(y|z)$$

TAS - SLAM

Folie 20

Beispiel Zustandsschätzung

- Der Roboter erhält eine zweite Messung z_2
- Wie ist $P(\text{open}|z_1, z_2)$



TAS - SLAM

Folie 21

Recursives Bayes'sches Updaten

$$P(x|z_1, \dots, z_n) = \frac{P(z_n|x, z_1, \dots, z_{n-1})P(x|z_1, \dots, z_{n-1})}{P(z_n|z_1, \dots, z_{n-1})}$$

Markov Annahme: z_n ist unabhängig von z_1, z_2, \dots, z_{n-1} bei gegebenem x .

$$\begin{aligned} P(x|y_1, \dots, z_n) &= \frac{P(z_n|x)P(x|z_1, \dots, z_{n-1})}{P(z_n|z_1, \dots, z_{n-1})} \\ &= \eta P(z_n|x)P(x|z_1, \dots, z_{n-1}) \\ &= \eta_{1\dots n} \prod_{i=1\dots n} P(z_i|x)P(x) \end{aligned}$$

TAS - SLAM

Folie 22

Beispiel: Zweite Messung

$$\begin{aligned} P(z_2|open = 0.5) &= P(z_2|\neg open) = 0.6 \\ P(open|z_1) = 2/3 & \quad P(\neg open|z_1) = 1/3 \end{aligned}$$

$$\begin{aligned} P(open|z_1, z_2) &= \frac{P(z_2|open)P(open|z_1)}{P(z_2|open)P(open|z_1) + P(z_2|\neg open)P(\neg open|z_1)} \\ &= \frac{\frac{1}{2} \cdot \frac{2}{3}}{\frac{1}{2} \cdot \frac{2}{3} + \frac{3}{5} \cdot 13} = \frac{5}{8} = 0.625 \end{aligned}$$

Beobachtung z_2 verringert die Wahrscheinlichkeit, dass die Tür offen ist.

Bayes Filters: Framework

➤ Gegeben:

- Folge von Beobachtungen z und Handlungen u :
 $d_t = \{u_1, z_2, \dots, u_{t-1}, z_t\}$
- Sensor Modell $P(z|x)$.
- Handlungs Modell $P(x|u, x')$.
- Prior Wahrscheinlichkeit des Systemzustandes $P(x)$.

➤ Gesucht:

- Schätzung des Zustandes X eines dynamischen Systems.
- Der posterior des Zustandes wird **Belief** genannt:

$$Bel(x_t) = P(x_t | u_1, z_2, \dots, u_{t-1}, z_t)$$

Bayes Filters

z = observation
 u = action
 x = state

$$Bel(x_t) = P(x_t | u_1, z_1, \dots, u_t, z_t)$$

Bayes $= \eta P(z_t | x_t, u_1, z_1, \dots, u_t) P(x_t | u_1, z_1, \dots, u_t)$

Markov $= \eta P(z_t | x_t) P(x_t | u_1, z_1, \dots, u_t)$

Total prob.

$$= \eta P(z_t | x_t) \int P(x_t | u_1, z_1, \dots, u_t, x_{t-1}) P(x_{t-1} | u_1, z_1, \dots, u_t) dx_{t-1}$$

Markov $= \eta P(z_t | x_t) \int P(x_t | u_t, x_{t-1}) P(x_{t-1} | u_1, z_1, \dots, u_t) dx_{t-1}$


$$= \eta P(z_t | x_t) \int P(x_t | u_t, x_{t-1}) Bel(x_{t-1}) dx_{t-1}$$

$$Bel(x_t) = \eta P(z_t | x_t) \int P(x_t | u_t, x_{t-1}) Bel(x_{t-1}) dx_{t-1}$$

1. Algorithm **Bayes_filter(Bel(x), d):**
2. $n=0$
3. If d is a **perceptual** data item z then
4. For all x do
5. $Bel'(x) = P(z | x) Bel(x)$
6. $\eta = \eta + Bel'(x)$
7. For all x do
8. $Bel'(x) = \eta^{-1} Bel'(x)$
9. Else if d is an **action** data item u then
10. For all x do
11. $Bel'(x) = \int P(x | u, x') Bel(x') dx'$
12. Return $Bel'(x)$

Beispiel

Lokalisierung



Abbildungen von Kurt Konolige, Stanford

TAS - SLAM