

# Technik Autonomer Systeme: Kalman Filter

Dirk Wollherr

*Lehrstuhl für Steuerungs- und Regelungstechnik  
Technische Universität München*

## Rückblick: Bayes Filter

### ➤ Schätzung

$$\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

### ➤ Korrektur

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$$

## Discrete Kalman Filter

Schätze den Zustand  $x$  eines zeit-diskreten, geregelten Prozesses, der durch die lineare zeitdiskrete Differenzgleichung

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

beschrieben wird, mit einer Messung

$$z_t = C_t x_t + \delta_t$$


6

## Components of a Kalman Filter

- $A_t$  Matrix (nxn), die beschreibt, wie sich der Zustand von  $t-1$  bis  $t$  entwickelt ohne Eingriff und Rauschen.
- $B_t$  Matrix (nxl), die beschreibt, wie  $u_t$  den Zustand von  $t$  bis  $t-1$  verändert.
- $C_t$  Matrix (kxn), die beschreibt, wie der Zustand  $x_t$  auf die Messung  $z_t$  abgebildet wird.
- $\varepsilon_t$  Zufallsvariablen, die das Prozess- und Messrauschen darstellen, die als unabhängig und normalverteilt angenommen werden mit den Kovarianzmatritzen  $R_t$  und  $Q_t$ .

7

## Kalman Filter Updates in 1D




8

## Kalman Filter Updates in 1D

$$bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - \bar{\mu}_t) \\ \sigma_t^2 = (1 - K_t)\bar{\sigma}_t^2 \end{cases} \quad \text{with} \quad K_t = \frac{\bar{\sigma}_t^2}{\bar{\sigma}_t^2 + \sigma_{obs,t}^2}$$

$$bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - C_t\bar{\mu}_t) \\ \Sigma_t = (I - K_tC_t)\bar{\Sigma}_t \end{cases} \quad \text{with} \quad K_t = \bar{\Sigma}_tC_t^T(C_t\bar{\Sigma}_tC_t^T + Q_t)^{-1}$$





9





## Kalman Filter Updates in 1D

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = a_t \mu_{t-1} + b_t u_t \\ \bar{\sigma}_t^2 = a_t^2 \sigma_{t-1}^2 + \sigma_{act,t}^2 \end{cases}$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t \end{cases}$$



## Kalman Filter Updates



## Lineare Gauss'sche Systeme: Initialisierung

- Initialer belief ist normalverteilt:

$$bel(x_0) = N(x_0; \mu_0, \Sigma_0)$$

## Lineare Gauss'sche Systeme: Dynamik

- Dynamik ist eine lineare Funktion des Zustands und des Eingriffs mit additivem Rauschen:

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

$$p(x_t | u_t, x_{t-1}) = N(x_t; A_t x_{t-1} + B_t u_t, R_t)$$

$$\begin{array}{ccc} \overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) & & bel(x_{t-1}) dx_{t-1} \\ \Downarrow & & \Downarrow \\ \sim N(x_t; A_t x_{t-1} + B_t u_t, R_t) & \sim & N(x_{t-1}; \mu_{t-1}, \Sigma_{t-1}) \end{array}$$

## Lineare Gauss'sche Systeme: Dynamik

$$\begin{aligned}
 \overline{bel}(x_t) &= \int p(x_t | u_t, x_{t-1}) \quad \quad \quad bel(x_{t-1}) \, dx_{t-1} \\
 &\quad \quad \quad \Downarrow \quad \quad \quad \Downarrow \\
 &\sim N(x_t; A_t x_{t-1} + B_t u_t, R_t) \quad \sim N(x_{t-1}; \mu_{t-1}, \Sigma_{t-1}) \\
 &\quad \quad \quad \Downarrow \\
 \overline{bel}(x_t) &= \eta \int \exp \left\{ -\frac{1}{2} (x_t - A_t x_{t-1} - B_t u_t)^T R_t^{-1} (x_t - A_t x_{t-1} - B_t u_t) \right\} \\
 &\quad \quad \quad \exp \left\{ -\frac{1}{2} (x_{t-1} - \mu_{t-1})^T \Sigma_{t-1}^{-1} (x_{t-1} - \mu_{t-1}) \right\} dx_{t-1} \\
 \overline{bel}(x_t) &= \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t \end{cases}
 \end{aligned}$$

## Lineare Gauss'sche Systeme: Messung

- Messungen sind lineare Funktionen eines Zustands mit additivem Rauschen:

$$z_t = C_t x_t + \delta_t$$

$$p(z_t | x_t) = N(z_t; C_t x_t, Q_t)$$

$$\begin{aligned}
 bel(x_t) &= \quad \eta \quad p(z_t | x_t) \quad \quad \quad \overline{bel}(x_t) \\
 &\quad \quad \quad \Downarrow \quad \quad \quad \Downarrow \\
 &\quad \quad \quad \sim N(z_t; C_t x_t, Q_t) \quad \quad \sim N(x_t; \bar{\mu}_t, \bar{\Sigma}_t)
 \end{aligned}$$

## Linear Gauss'sche Systeme: Messung

$$\begin{aligned}
 bel(x_t) &= \eta \quad p(z_t | x_t) & \overline{bel}(x_t) \\
 &\Downarrow & \Downarrow \\
 &\sim N(z_t; C_t x_t, Q_t) & \sim N(x_t; \bar{\mu}_t, \bar{\Sigma}_t) \\
 &\Downarrow \\
 bel(x_t) &= \eta \exp\left\{-\frac{1}{2}(z_t - C_t x_t)^T Q_t^{-1}(z_t - C_t x_t)\right\} \exp\left\{-\frac{1}{2}(x_t - \bar{\mu}_t)^T \bar{\Sigma}_t^{-1}(x_t - \bar{\mu}_t)\right\} \\
 \\ 
 bel(x_t) &= \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - C_t \bar{\mu}_t) \\ \Sigma_t = (I - K_t C_t) \bar{\Sigma}_t \end{cases} & \text{with } K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}
 \end{aligned}$$

## Kalman Filter Algorithmus

1. Algorithmus **Kalman\_filter**( $\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$ ):
2. Schätzung:
3.  $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$
4.  $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t$
5. Korrektur:
6.  $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$
7.  $\mu_t = \bar{\mu}_t + K_t(z_t - C_t \bar{\mu}_t)$
8.  $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$
9. Return  $\mu_t, \Sigma_t$

## Kalman Filter: Grundlagen

### Voraussetzungen:

- lineares, zeitdiskretes Modell
- Gaußsches, weißes Rauschen

### Modell:

$$x_{k+1} = A_k x_k + B u_k + w_k$$

$$z_k = H_k x_k + v_k$$

### Interne Variablen:

- Systemzustand
- Kovarianz-Matrix des Zustands

### Time-Update Gleichungen:

$$\hat{x}_{k+1}^- = A_k \hat{x}_k + B u_k$$

$$P_{k+1}^- = A_k P_k A_k^T + Q_k$$

### Time-Update (Prädiktion):

- Schätzung des Systemzustands aufgrund von Eingangsdaten

### Measurement-Update Gleichungen:

$$K_k = P_k^- H_k^T (H_k P_k^- H_k^T + R_k)^{-1}$$

$$\hat{x}_k = \hat{x}_k^- + K_k (z_k - H_k \hat{x}_k^-)$$

$$P_k = (I - K_k H_k) P_k^-$$

### Measurement Update (Korrektur):

- Korrektur des Systemzustands mittels Messung des Ausgangs

TAS - SLAM

Folie 18

## Kalman Filter

Initial estimates for  $\hat{x}_k^-$  and  $P_k^-$

### Time update ("Predict")

- (1) Project the state ahead

$$\hat{x}_{k+1}^- = A_k \hat{x}_k + B u_k$$

- (2) Project the error covariance ahead

$$P_{k+1}^- = A_k P_k A_k^T + Q_k$$

### Measurement update ("Correct")

- (1) Compute the Kalman gain

$$K_k = P_k^- H_k^T (H_k P_k^- H_k^T + R_k)^{-1}$$

- (2) Update estimate with measurement  $z_k$

$$\hat{x}_k = \hat{x}_k^- + K_k (z_k - H_k \hat{x}_k^-)$$

- (3) Update the error covariance

$$P_k = (I - K_k H_k) P_k^-$$

TAS - SLAM

Folie 19





## Sensorfusion mit Kalman-Filter

Fahrzeug ausgestattet mit

- Odometrie
- Gyroskop
- Global Positioning System



## Odometriemodell

**Funktionsprinzip:**

- Messung der eigenen Fortbewegung durch Erfassung der Radwinkel
- optische oder magnetische Encoder

**Modellierung der Messfehler:**

$$\Delta s^o = \frac{1}{1 + \epsilon} \cdot \Delta s + \Delta s_{noise}$$

- systematische Fehler:
  - fehlerhafter Radradius
  - fehlerhafte Radstellung
- stochastische Fehler:
  - Radschlupf

## Beispiel

### Gyroskop

#### Funktionsprinzip:

- Messung der Drehrate um die Vertikalachse
- Glasfaser-Gyroskop (FOG *fiber optical gyroscope*)

#### Modellierung der Messfehler:

$$\dot{\psi}^g = K^g \dot{\psi} (\cos \alpha + \delta_1) + \delta_2 + \delta_{noise}$$

systematische Fehler:

- Verkipfung von Sensorachse zur Drehrichtung  $\alpha$
- Schwankung des Skalierungsfaktors  $\delta_1$
- Abgleichfehler (Offset)  $\delta_2$

➤ stochastische Fehler:

- (thermisches) Messrauschen  $\delta_{noise}$

TAS - SLAM

Folie 25

## Beispiel

### Global Positioning System (GPS)

#### Satellitengestützte Navigation:

- absolute Messung über 24 GPS-Satelliten
- Positionsbestimmung aus Laufzeitdifferenz der Signale
- mindestens 3 bzw. 4 Satelliten müssen sichtbar sein



#### Messfehler:

- Quantisierungseffekte
- Rauschen, Interferenzen (mehrere Signalfade)
- Langzeitdrift durch atmosphärische Schwankungen

#### Erweiterung:

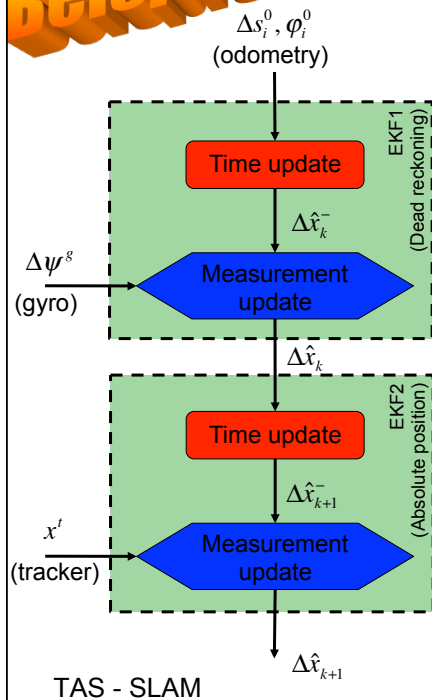
- DGPS (*differential GPS*)
- Korrektursignale durch terrestrische Sender

TAS - SLAM



# Beispiel

## Kalmanfilter



TAS - SLAM

Folie 27

### Aufbau:

- kaskadierte Architektur
- Kalmanfilter 1: schätzen des Positionsincrements
- Kalmanfilter 2: schätzen der absoluten Position

### Implementierung:

- zeitdiskrete Berechnung
- verschiedene Sensorraten

### Abtastraten:

- Odometrie: 125 Hz
- Gyroskop: 125 Hz
- Tracker: 10 Hz
- GPS: 1 Hz

# Beispiel

## Beispieltrajektorie

### Testbedingungen:

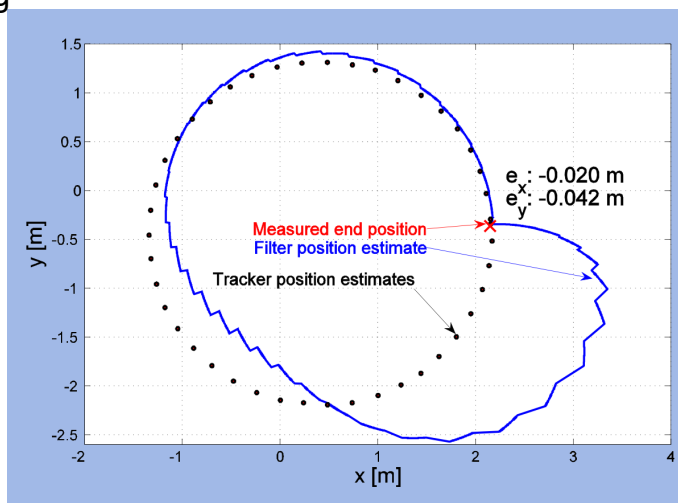
- unregelmäßige Kreisbahn
- fehlerhafte Initialisierung der Orientierung:  $+90^\circ$

### Signale:

- Odometrie
- Gyroskop
- Positionstracker

### Schätzwerte:

- Position
- Orientierung



TAS - SLAM

Folie 28

## Kalman Filter Zusammenfassung

- Sehr effizient: Polinomial mit Dimension der Messungen  $k$  und des Zustands  $n$ :  
 $O(k^{2.376} + n^2)$
- Optimal für lineare Gauss'sche Systeme!
- Die meisten Probleme in der Robotik sind nichtlinear!

Going non-linear

## EXTENDED KALMAN FILTER

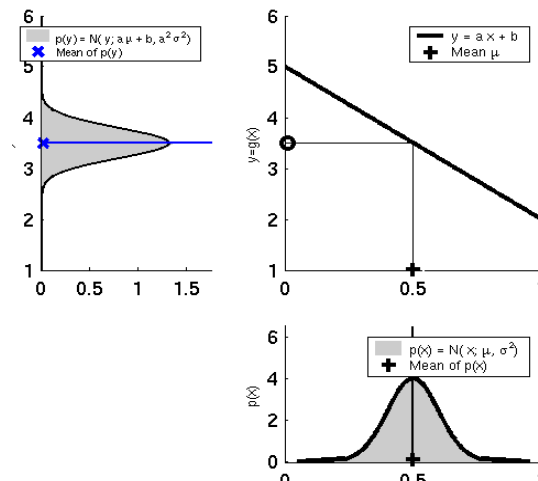
## Nichtlineare dynamische Systeme

- Die meisten Probleme in der Robotik sind nichtlinear

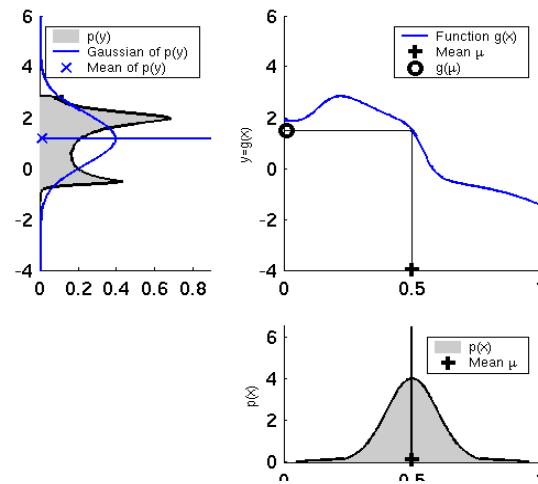
$$x_t = g(u_t, x_{t-1})$$

$$z_t = h(x_t)$$

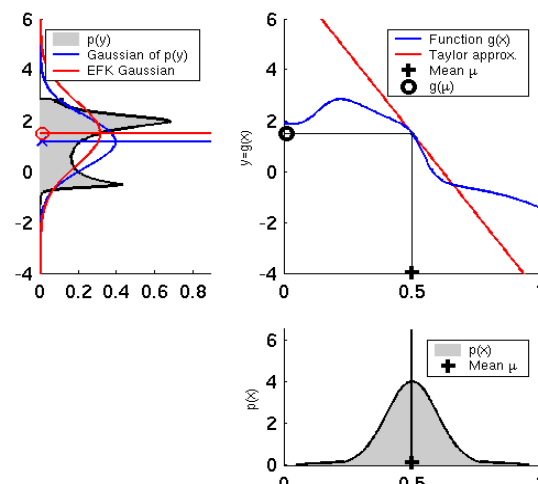
## Annahme der Linearität



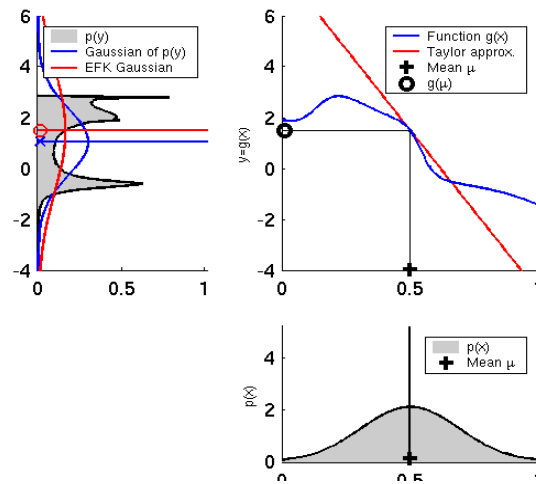
## Nichtlineare Abbildungsfunktion




## EKF Linearisierung (1)



## EKF Linearisierung (2)



## EKF Linearisierung (3)



## EKF Linearisierung: Taylor Reihe erster Ordnung

### ➤ Schätzung:

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + \frac{\partial g(u_t, \mu_{t-1})}{\partial x_{t-1}} (x_{t-1} - \mu_{t-1})$$

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t (x_{t-1} - \mu_{t-1})$$

### ➤ Korrektur:

$$h(x_t) \approx h(\bar{\mu}_t) + \frac{\partial h(\bar{\mu}_t)}{\partial x_t} (x_t - \bar{\mu}_t)$$

$$h(x_t) \approx h(\bar{\mu}_t) + H_t (x_t - \bar{\mu}_t)$$

## EKF Algorithmus

**1.** `Extended_Kalman_filter(  $\mu_{t-1}, \Sigma_{t-1}, u_t, \hat{y}_t$ ):`

**2.** Schätzung:

**3.**  $\bar{\mu}_t = g(u_t, \mu_{t-1})$  ←  $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$

**4.**  $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + R_t$  ←  $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t$

**5.** Korrektur:

**6.**  $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$  ←  $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$

**7.**  $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$  ←  $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$

**8.**  $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$  ←  $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$

**9.** Return  $\mu_t, \Sigma_t$   $H_t = \frac{\partial h(\bar{\mu}_t)}{\partial x_t}$   $G_t = \frac{\partial g(u_t, \mu_{t-1})}{\partial x_{t-1}}$



## Lokalisierung

“Using sensory information to locate the robot in its environment is the most fundamental problem to providing a mobile robot with autonomous capabilities.” [Cox '91]

➤ **Gegeben**

- Umgebungskarte
- Folge von Messungen

➤ **Gesucht**

- Schätzung der Position des Roboters

➤ **Problemklassifikation**

- Position tracking
- Globale Lokalisierung
- Kidnapped robot problem (recovery)

## EKF Zusammenfassung

- **Sehr effizient:** Polinomial mit Dimension des Messungen  $k$  und des Zustands  $n$ :

$$O(k^{2.376} + n^2)$$

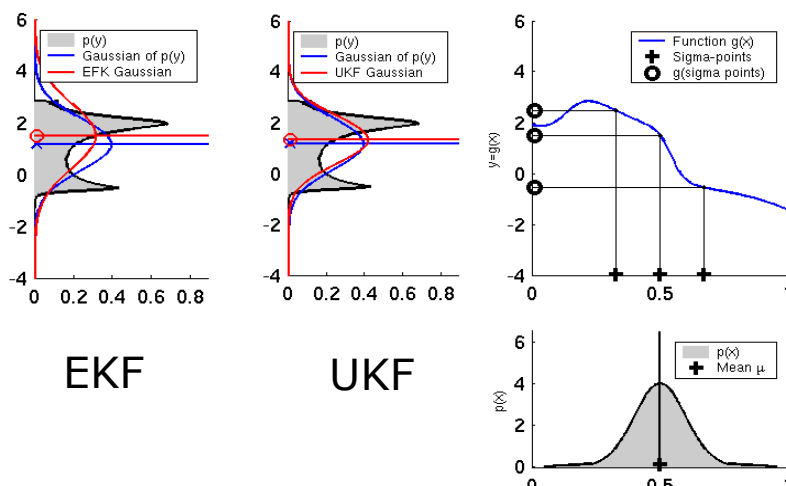
- **Nicht optimal!**
- **Kann divergieren** wenn nichtlinearitäten zu groß!
- **Funktioniert überraschend gut**, auch wenn Annahmen verletzt sind!

Going unscented

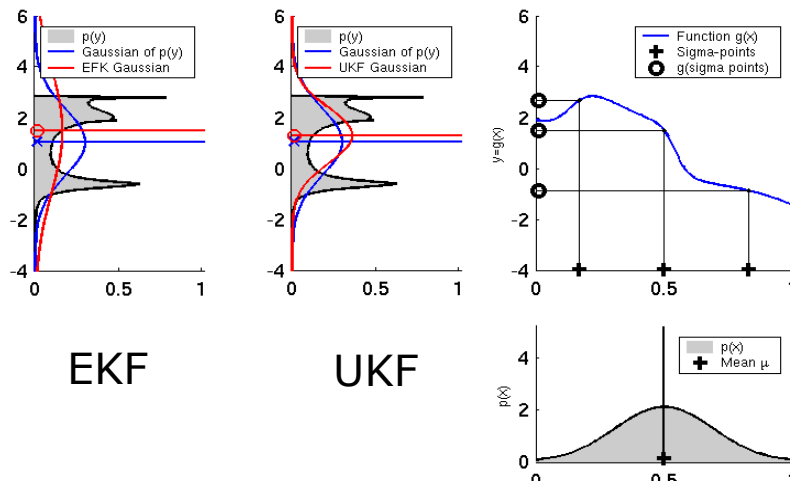
## UNSCENTED KALMAN FILTER

50


### Linearisierung mit der Unscented Transformation



## UKF Sigma-Point Estimate (2)



## UKF Sigma-Point Estimate (3)



## UKF Zusammenfassung

- Sehr effizient: Gleiche Komplexität wie EKF, um konstanten Faktor langsamer in typischen praktischen Anwendungen
- Bessere Linearisierung als EKF: Genau in den ersten zwei Termen der Taylor Entwicklung (EKF nur erster Term)
- Frei von Ableitungen: Keine Jacobi-Matrizen notwendig
- Auch nicht optimal!

63