

Advanced Robot Perception

Fortgeschrittene Konzepte der Wahrnehmung für
Robotersysteme

Georg von Wichert, Siemens Corporate Technology

Heutiges Thema: Aktive Wahrnehmung

- Wahrnehmungsprozess immer fehlerbehaftet
 - „Signal-Rausch-Verhältnis“ in der Robotik immer sehr niedrig, d.h. massive Störungen
 - Expliziter Umgang mit den Fehlern!
 - Bayes-Filter als Modell für Wahrnehmungsvorgang unter Unsicherheit



$$Bel(x_t) = \underbrace{\eta P(z_t | x_t)}_{\text{Korrektur/ Mess-Update}} \underbrace{\int P(x_t | u_t, x_{t-1})}_{\text{Prädiktion / Zeit-Update}} Bel(x_{t-1}) dx_{t-1}$$

Korrektur/ Mess-Update


Prädiktion / Zeit-Update

Heutiges Thema: Aktive Wahrnehmung

- Was kann ich als Maschine tun, um meine Wahrnehmungsergebnisse zu verbessern?
- Speziell in der Robotik: Roboter sind beweglich
 - Aktive Steuerung der Wahrnehmung möglich
 - Beispiel: Einnehmen eines „guten“ Standpunktes
 - Beispiel: „Gute“ Konfiguration der Sensoren
- Was heißt hier „gut“?

Beispiel: Datenfusion mit dem Extended Kalman Filter

- Beobachtung eines beweglichen Objekts in der Ebene mit zwei ungerichteten Abstandssensoren



$$\mathbf{p}_i = \begin{bmatrix} p_{i1} \\ p_{i2} \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \quad \mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$

$$z_i = \|\mathbf{x} - \mathbf{p}_i\| = \sqrt{(x_1 - p_{i1})^2 + (x_2 - p_{i2})^2}$$

Sensormodell:

$$\mathbf{z}_t = \mathbf{h}(\mathbf{x}_t) + \nu_t = \begin{bmatrix} z_1(\mathbf{x}_t) \\ z_2(\mathbf{x}_t) \end{bmatrix} + \nu_t$$


Messrauschen: $\nu_t \sim \mathcal{N}(0, \mathbf{Q})$

Prozessmodell:


$$\mathbf{x}_t = \mathbf{g}(\mathbf{x}_{t-1}, \mathbf{u}_t) + \xi_t = \begin{bmatrix} 1 & 0 & T & 0 \\ 0 & 1 & 0 & T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \mathbf{x}_{t-1} + \xi_t$$


Prozessrauschen: $\xi_t \sim \mathcal{N}(0, \mathbf{R})$


Beispiel: Datenfusion mit dem Extended Kalman Filter



- Beobachtung eines beweglichen Objekts in der Ebene mit zwei ungerichteten Abstandssensoren
- Wie sieht die ideale Konfiguration aus?
 - Rechtwinkliges Dreieck








Beispiel: Datenfusion mit dem Extended Kalman Filter

- Beobachtung eines beweglichen Objekts in der Ebene mit zwei ungerichteten Abstandssensoren



$$\mathbf{p}_i = \begin{bmatrix} p_{i1} \\ p_{i2} \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \quad \mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$

$$z_i = \|\mathbf{x} - \mathbf{p}_i\| = \sqrt{(x_1 - p_{i1})^2 + (x_2 - p_{i2})^2}$$

Sensormodell:

$$\mathbf{z}_t = \mathbf{h}(\mathbf{x}_t) + \nu_t = \begin{bmatrix} z_1(\mathbf{x}_t) \\ z_2(\mathbf{x}_t) \end{bmatrix} + \nu_t$$

Messrauschen: $\nu_t \sim \mathcal{N}(0, \mathbf{Q})$


Prozessmodell:

$$\mathbf{x}_t = \mathbf{g}(\mathbf{x}_{t-1}, \mathbf{u}_t) + \xi_t = \begin{bmatrix} 1 & 0 & T & 0 \\ 0 & 1 & 0 & T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \mathbf{x}_{t-1} + \xi_t$$

Prozessrauschen: $\xi_t \sim \mathcal{N}(0, \mathbf{R})$


Aktive Wahrnehmung

- Steuerung von a zur Laufzeit
- Denkbare Stellstrategie:
 - Mögl. rechtwinkliges Dreieck herstellen!
 - Natürlich nur bei diesem Aufbau sinnvoll!
- Wir suchen ein **grundlegendes Prinzip** für die Steuerung der Wahrnehmungsparameter bzw. Wahrnehmungsaktionen!
- Frage: Können wir quantifizieren, wie viel wir die **Unsicherheit** über den unsicheren System/Umweltzustand durch die jeweilige Messung verringern?
 - Maximieren!



Informationstheorie

- Entwickelt für Kommunikationstechnik
 - "A Mathematical Theory of Communication", 1948
 - Zentrales Thema: Übertragung von Information über einen gestörten Kanal
 - Applikationen in Kodierung und Kryptographie
- Wir werden das hier ohne Herleitung einführen
 - Details: Spezialvorlesung, **Lehrstuhl für Nachrichtentechnik**, Prof. Kramer
 - Wir wollen hier nur sehen, dass/wie wir die Informationstheorie für unsere Zwecke nutzen können!



Claude Elwood Shannon
30.4.1916 – 24.2.2001

Was ist Information?


- Für eine diskrete „Quelle“ mit einem endlichen „Alphabet“ $\mathcal{X} = \{x_0, x_1, \dots, x_{M-1}\}$, wobei die Wahrscheinlichkeit für die jeweiligen Ereignisse durch $P(X = x_k) = p_k$ gegeben ist, ist der Informationsgehalt

$$I(x_k) = \log \frac{1}{p_k} = -\log(p_k)$$

- Logarithmus zur Basis 2: Information in bit

Was ist Information?

$$I(x_k) = \log \frac{1}{p_k} = -\log(p_k)$$



- Der Informationsgehalt entspricht dem „Grad der Überraschung“ bei der Beobachtung eines Ereignisses x_k
- Je seltener das Ereignis, umso größer ist der Informationsgehalt
 - Wenn ein häufiges Ereignis auftritt, erhalten wir wenig Information

Entropie

- Entropie ist der **mittlere Informationsgehalt** eines Ereignisses

$$H(X) = E_x[I(x)] = \sum_k P(X = x_k) I(x_k) = - \sum_k p_k \log p_k$$

- Das Äquivalent für kontinuierliche Zufallsvariablen ist die differentielle Entropie

$$H(X) = - \int p(x) \log(p(x)) \, dx$$

- Die Entropie ist ein Maß für die Unsicherheit der Verteilung $p(x)$.
- Sie ist maximal, wenn $p(x)$ eine Gleichverteilung ist.

Bedingte (differentielle) Entropie

- Nehmen wir an, wir haben zwei Zufallsvariablen x und z mit einer Verbundverteilung $p(x, z)$
- Wie groß ist die Entropie von x , wenn wir z kennen?


$$\begin{aligned} H(X|Z) &= - \iint p(x, z) \log(p(x|z)) \, dx \, dz \\ &= - \iint p(x|z)p(z) \log(p(x|z)) \, dx \, dz \\ &= - \int p(z) \underbrace{\int p(x|z) \log(p(x|z)) \, dx}_{H(X|z)} \, dz = \int p(z) H(X|z) \, dz = E_z(H(X|z)) \end{aligned}$$

$H(X|z)$

← z.B. Entropie von x , nachdem wir eine bestimmte Messung z gemacht haben

Aktive Wahrnehmung

- Steuerung von a zur Laufzeit
- Denkbare Stellstrategie:
 - Mögl. rechtwinkliges Dreieck herstellen!
 - Natürlich nur bei diesem Aufbau sinnvoll!
- Wir suchen ein **grundlegendes Prinzip** für die Steuerung der Wahrnehmungsparameter bzw. Wahrnehmungsaktionen!



Minimieren der Entropie nach der Messung

$$H_a(X_t | Z_t) \quad \text{wobei} \quad bel(x_t) = p(x_t | z_t(a))$$

durch **geeignete Wahl** der Aktion a

Entropie & Kalman-Filter (EKF)

Prädiktion:

$$\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

$$\bar{\mu}_t = g(u_t, \mu_{t-1})$$

$$\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + R_t$$

$$G_t = \left. \frac{\partial g(u_t, x_{t-1})}{\partial x_{t-1}} \right|_{\mu_{t-1}}$$

Korrektur:

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$$

$$bel(x_t) = p(x_t | z_t)$$

$$\sim N(x_t; \mu_t, \Sigma_t)$$

$$K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$$

$$\begin{cases} \mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t)) \\ \Sigma_t = (I - K_t H_t) \bar{\Sigma}_t \end{cases}$$

$$H_t = \left. \frac{\partial h(x_t)}{\partial x_t} \right|_{\bar{\mu}_t}$$

Aktive Wahrnehmung mit EKF

Ansatz: Minimieren der Entropie nach der Messung $z(a)$

$$\begin{aligned} H_a(X_t|Z_t) &= - \int p(z_t(a)) \int p(x_t|z_t(a)) \log(p(x_t|z_t(a))) dx_t dz_t(a) \\ &= \int p(z_t(a)) H(X_t|z_t(a)) dz_t(a) \end{aligned}$$

Spezialisierung auf EKF:

Einsetzen!



$$p(x | z_t(a)) \sim N(x_t; \mu_t, \Sigma_t)$$

Entropie der n-dimensionalen Normalverteilung:

$$H(X) = \frac{n}{2} + \frac{1}{2} \log((2\pi)^n |\Sigma|) \quad x \in \mathbb{R}^n$$

Aktive Wahrnehmung mit EKF

Ansatz: Minimieren der Entropie nach der Messung $z(a)$

$$\begin{aligned} H_a(X_t|Z_t) &= - \int p(z_t(a)) \int p(x_t|z_t(a)) \log(p(x_t|z_t(a))) \, dx_t \, dz_t(a) \\ &= \int p(z_t(a)) H(X_t|z_t(a)) \, dz_t(a) \\ &= \int p(z_t(a)) \left(\frac{n}{2} + \frac{1}{2} \log((2\pi)^n |\Sigma_t|) \right) \, dz_t(a) \\ &= \int \left(\frac{n}{2} p(z_t(a)) + \frac{1}{2} p(z_t(a)) \log((2\pi)^n |\Sigma_t|) \right) \, dz_t(a) \\ &= \underbrace{\frac{n}{2} \int p(z_t(a)) \, dz_t(a)}_c + \frac{1}{2} \int p(z_t(a)) \log((2\pi)^n |\Sigma_t|) \, dz_t(a) \end{aligned}$$

Aktive Wahrnehmung mit EKF

Achtung!
 $H_a(X_t|Z_t) \neq H_{t,a}$

Ansatz: Minimieren der Entropie nach der Messung $z(a)$

$$H_a(X_t|Z_t) = c + \frac{1}{2} \int p(z_t(a)) \log((2\pi)^n |\Sigma_t|) dz_t(a)$$

Kalmanfilter: Σ_t ist unabhängig von z !!!

$$= c + \log((2\pi)^n |\Sigma_{t,a}|) \underbrace{\int \frac{p(z(a))}{2} dz(a)}_d$$

$$K_{t,a} = \bar{\Sigma}_t H_{t,a}^T (H_{t,a} \bar{\Sigma}_t H_{t,a}^T + Q_t)^{-1}$$

$$\mu_t = \bar{\mu}_t + K_{t,a} (z_t - h_a(\bar{\mu}_t))$$

$$\Sigma_{t,a} = (I - K_{t,a} H_{t,a}) \bar{\Sigma}_t$$

$$H_{t,a} = \left. \frac{\partial h_a(x_t)}{\partial x_t} \right|_{\bar{\mu}_t}$$

Um $H_a(X_t|Z_t)$ zu minimieren, müssen wir durch passende Wahl von a_t die Determinante von $\Sigma_{t,a}$ minimieren!!!

$$a_t^* = \arg \min_{a_t} |\Sigma_{t,a}|$$

Weil $\Sigma_{t,a}$ nicht von z_t abhängt, können wir das bereits vor der tatsächlichen Messung ausrechnen!

Aktive Wahrnehmung

Ansatz: Minimieren der Entropie nach der Messung $z(a)$

$$a_t^* = \arg \min_{a_t} H_a(X_t|Z_t) \quad \xrightarrow{\text{Kalman-Filter}} \quad a_t^* = \arg \min_{a_t} |\Sigma_{t,a}|$$

- Warum ist das toll?
 - Grundlegendes Prinzip! Das wollten wir doch....
 - Unabhängig von dem spezifischen Problem!
 - Das genaue Prozess und Beobachtungsmodell haben wir für die prinzipielle Betrachtung gar nicht erst benötigt
 - Das Modell können wir jetzt einfach in die Formeln einsetzen

$$H_{t,a} = \left. \frac{\partial h_a(x_t)}{\partial x_t} \right|_{\bar{\mu}_t}$$

Environment Perception: MPG Framework for 6D Pose Estimation

Objectives


- Full exploitation of all available information related to pose
- Consistent handling of uncertainties
- Appropriate handling of orientation
- Efficiency

Approach

- 6D pose representation:
Dual quaternions
- Strictly probabilistic (poses, observation models)
- Representation of pdfs:
“Mixtures of projected Gaussians” (MPGs)



Inferred
pdfs for
6D poses



After
fusion



Using
more
features



- Unified framework for incremental fusion of diverse – possibly “weak” - observations / information sources (“Forward reasoning”)
- Efficiency due to parametric representation and controlled approximations

Active Perception for Robots: Example

Initial scenario



Observations

