

# Advanced Robot Perception

Fortgeschrittene Konzepte der Wahrnehmung für  
Robotersysteme

Georg von Wichert, Siemens Corporate Technology

# Nochmal 2. Hausaufgabe

- Berechnung der Kovarianzmatrix

$$\text{Cov}(X) = \mathbb{E} \left( (X - \mu)(X - \mu)^T \right) = \mathbb{E}(XX^T) - \mu\mu^T.$$

$$E(x) = \int xp(x)dx$$

$$E(X) = \sum XP(X)$$

# Nochmal 2. Hausaufgabe

- Berechnung der Kovarianzmatrix

$$\mu = E(\mathbf{x}) = \int \mathbf{x} \cdot p(\mathbf{x}) d\mathbf{x}$$

$$\Sigma = E(\mathbf{x} - \mu) = \int (\mathbf{x} - \mu)^T (\mathbf{x} - \mu) \cdot p(\mathbf{x}) d\mathbf{x}$$

- In unserem Fall ist eine geschlossene Lösung schwierig

$$p(\mathbf{x}) = p(\mathbf{x}|z) = \dots$$

# Probabilistisches Sensormodell


## Physikalisches Modell des Messvorgangs

- Punktweise Projektion der SIFT-Merkmalpunkte in die Bilder der Beiden Kameras


$$\tilde{\mathbf{x}} = \begin{pmatrix} f_x & s & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} (R \quad \mathbf{t}) \tilde{\mathbf{p}}_w$$

## Wesentliche Fehlerquellen

- Fehler bei der Detektion der SIFT-Merkmalpunkte
  - (Modellfehler im 3D Objektmodell)
- müssen im Sensormodell berücksichtigt werden



# Zur Herleitung des Messmodells




$$\tilde{\mathbf{s}} = \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} R & \mathbf{t} \end{pmatrix} \tilde{\mathbf{p}}_w + \nu$$

$$\nu \sim N(0, Q)$$

Normalverteiltes Rauschen mit  
Kovarianzmatrix  $Q$

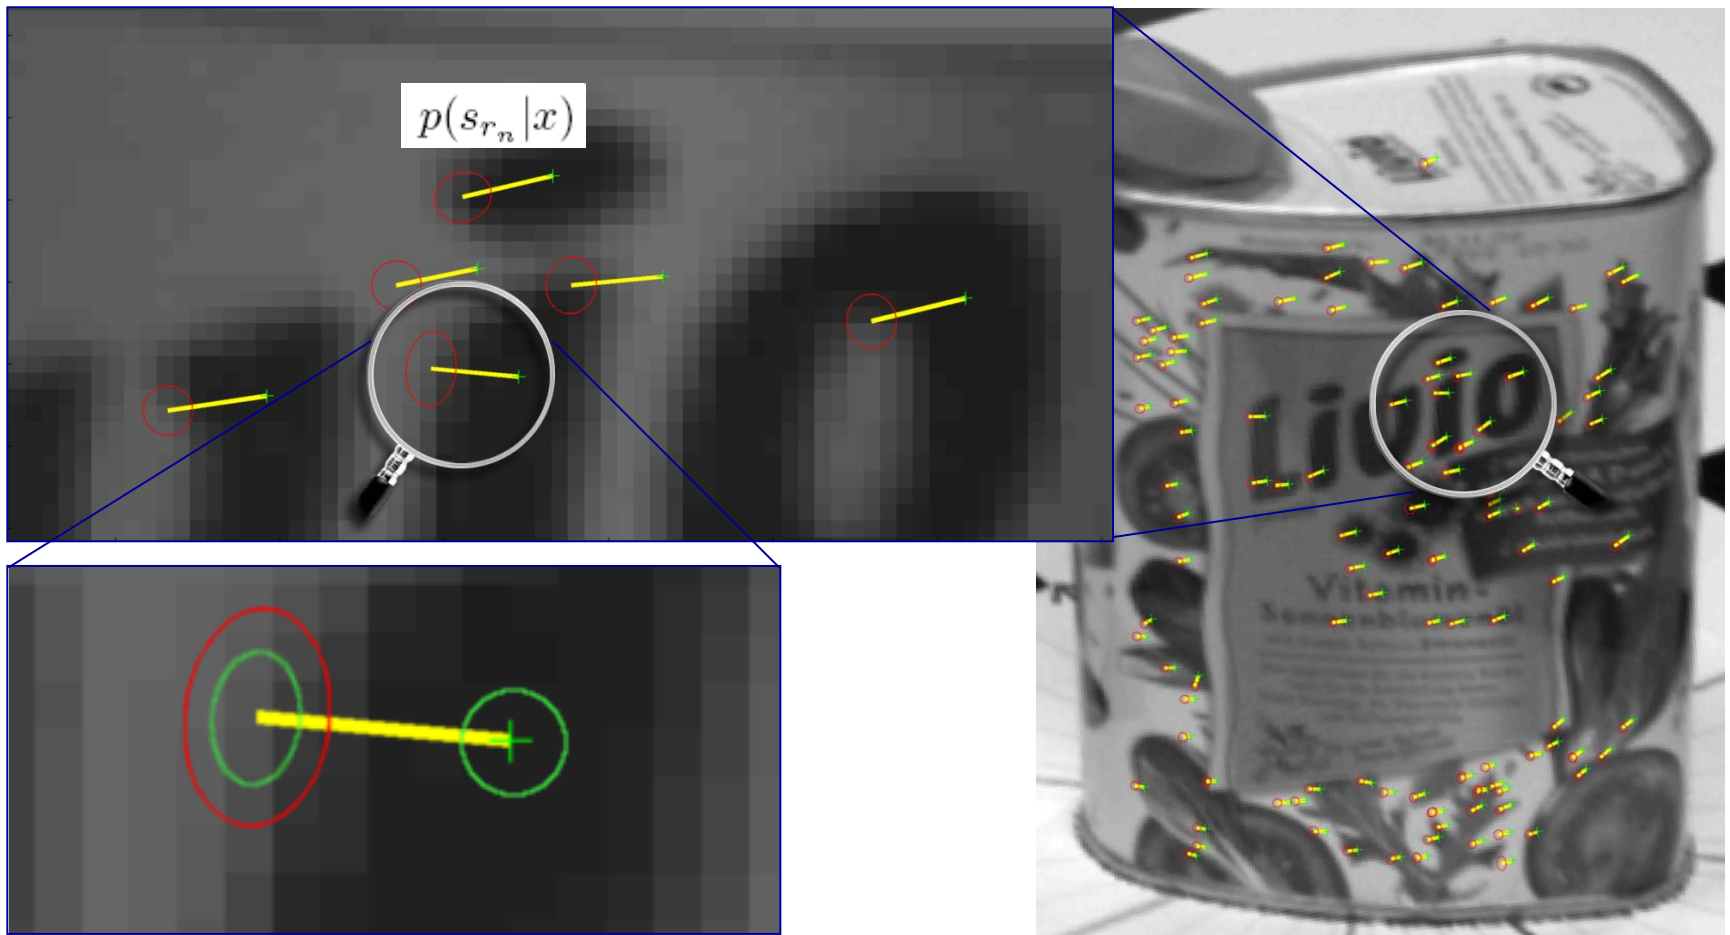
# Probabilistisches Sensormodell



- Projektion der Modellfehler in die jeweilige Bildebene
- Gauß'sche Modellierung des Detektionsfehlers
- Alle Features werden als statistisch unabhängig angenommen

# Probabilistisches Sensormodell

- Beispiel für eine Teilmessung



# Probabilistisches Sensormodell

- Vergleich zweier Lagehypothesen





# Nochmal 2. Hausaufgabe

- Berechnung der Kovarianzmatrix

$$\mu = E(\mathbf{x}) = \int \mathbf{x} \cdot p(\mathbf{x}) d\mathbf{x}$$

$$\Sigma = E(\mathbf{x} - \mu) = \int (\mathbf{x} - \mu)^T (\mathbf{x} - \mu) \cdot p(\mathbf{x}) d\mathbf{x}$$

- In unserem Fall ist eine geschlossene Lösung schwierig

$$p(\mathbf{x}) = p(\mathbf{x}|z) = \dots$$


# Monte-Carlo-Integration

- Ersatz des Integrals durch eine Summe über eine gleichverteilte Stichprobe

$$I = \int_{\Omega} f(\bar{\mathbf{x}}) d\bar{\mathbf{x}} \quad \Rightarrow \quad I \approx Q_N \equiv V \frac{1}{N} \sum_{i=1}^N f(\bar{\mathbf{x}}_i) = V \langle f \rangle$$

$$V = \int_{\Omega} d\bar{\mathbf{x}}$$

$$\bar{\mathbf{x}}_1, \dots, \bar{\mathbf{x}}_N \in \Omega,$$



# Vorletzes Mal: Aktive Wahrnehmung

- Wahrnehmungsprozess immer fehlerbehaftet
  - „Signal-Rausch-Verhältnis“ in der Robotik immer sehr niedrig, d.h. massive Störungen
  - Expliziter Umgang mit den Fehlern!
  - Bayes-Filter als Modell für Wahrnehmungsvorgang unter Unsicherheit



$$Bel(x_t) = \underbrace{\eta P(z_t | x_t)}_{\text{Korrektur/ Mess-Update}} \underbrace{\int P(x_t | u_t, x_{t-1})}_{\text{Prädiktion / Zeit-Update}} Bel(x_{t-1}) dx_{t-1}$$

Korrektur/ Mess-Update


Prädiktion / Zeit-Update

# Aktive Wahrnehmung

- Was kann ich als Maschine tun, um meine Wahrnehmungsergebnisse zu verbessern?
- Speziell in der Robotik: Roboter sind beweglich
  - Aktive Steuerung der Wahrnehmung möglich
  - Beispiel: Einnehmen eines „guten“ Standpunktes
  - Beispiel: „Gute“ Konfiguration der Sensoren
- Was heißt hier „gut“?

# Beispiel: Datenfusion mit dem Extended Kalman Filter

- Beobachtung eines beweglichen Objekts in der Ebene mit zwei ungerichteten Abstandssensoren



$$\mathbf{p}_i = \begin{bmatrix} p_{i1} \\ p_{i2} \end{bmatrix} \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \quad \mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$$

$$z_i = \|\mathbf{x} - \mathbf{p}_i\| = \sqrt{(x_1 - p_{i1})^2 + (x_2 - p_{i2})^2}$$

Sensormodell:

$$\mathbf{z}_t = \mathbf{h}(\mathbf{x}_t) + \nu_t = \begin{bmatrix} z_1(\mathbf{x}_t) \\ z_2(\mathbf{x}_t) \end{bmatrix} + \nu_t$$


Messrauschen:  $\nu_t \sim \mathcal{N}(0, \mathbf{Q})$

Prozessmodell:

$$\mathbf{x}_t = \mathbf{g}(\mathbf{x}_{t-1}, \mathbf{u}_t) + \xi_t = \begin{bmatrix} 1 & 0 & T & 0 \\ 0 & 1 & 0 & T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \mathbf{x}_{t-1} + \xi_t$$

Prozessrauschen:  $\xi_t \sim \mathcal{N}(0, \mathbf{R})$


# Beispiel: Datenfusion mit dem Extended Kalman Filter



- Beobachtung eines beweglichen Objekts in der Ebene mit zwei ungerichteten Abstandssensoren
- Wie sieht die ideale Konfiguration aus?
  - Rechtwinkliges Dreieck


# Aktive Wahrnehmung

- Steuerung von  $a$  zur Laufzeit
- Denkbare Stellstrategie:
  - Mögl. rechtwinkliges Dreieck herstellen!
  - Natürlich nur bei diesem Aufbau sinnvoll!
- Wir suchen ein **grundlegendes Prinzip** für die Steuerung der Wahrnehmungsparameter bzw. Wahrnehmungsaktionen!
- Frage: Können wir quantifizieren, wie viel wir die **Unsicherheit** über den unsicheren System/Umweltzustand durch die jeweilige Messung verringern?
  - Maximieren!



# Informationstheorie

- Entwickelt für Kommunikationstechnik
  - "A Mathematical Theory of Communication", 1948
    - Zentrales Thema: Übertragung von Information über einen gestörten Kanal
    - Applikationen in Kodierung und Kryptographie
- Wir werden das hier ohne Herleitung einführen
  - Details: Spezialvorlesung, **Lehrstuhl für Nachrichtentechnik**, Prof. Kramer
  - Wir wollen hier nur sehen, dass/wie wir die Informationstheorie für unsere Zwecke nutzen können!



**Claude Elwood Shannon**  
30.4.1916 – 24.2.2001



# Entropie

- Entropie ist der **mittlere Informationsgehalt** eines Ereignisses

$$H(X) = E_x[I(x)] = \sum_k P(X = x_k) I(x_k) = - \sum_k p_k \log p_k$$

- Das Äquivalent für kontinuierliche Zufallsvariablen ist die differentielle Entropie

$$H(X) = - \int p(x) \log(p(x)) \, dx$$

- Die Entropie ist ein Maß für die Unsicherheit der Verteilung  $p(x)$ .
- Sie ist maximal, wenn  $p(x)$  eine Gleichverteilung ist.

# Bedingte (differentielle) Entropie

- Nehmen wir an, wir haben zwei Zufallsvariablen  $x$  und  $z$  mit einer Verbundverteilung  $p(x, z)$
- Wie groß ist die Entropie von  $x$ , wenn wir  $z$  kennen?


$$\begin{aligned} H(X|Z) &= - \iint p(x, z) \log(p(x|z)) \, dx \, dz \\ &= - \iint p(x|z)p(z) \log(p(x|z)) \, dx \, dz \\ &= - \int p(z) \underbrace{\int p(x|z) \log(p(x|z)) \, dx}_{H(X|z)} \, dz = \int p(z) H(X|z) \, dz = E_z(H(X|z)) \end{aligned}$$

$H(X|z)$

← z.B. Entropie von  $x$ , nachdem wir eine bestimmte Messung  $z$  gemacht haben

# Aktive Wahrnehmung

- Steuerung von  $a$  zur Laufzeit
- Denkbare Stellstrategie:
  - Mögl. rechtwinkliges Dreieck herstellen!
  - Natürlich nur bei diesem Aufbau sinnvoll!
- Wir suchen ein **grundlegendes Prinzip** für die Steuerung der Wahrnehmungsparameter bzw. Wahrnehmungsaktionen!



Minimieren der Entropie nach der Messung

$$H_a(X_t | Z_t) \quad \text{wobei} \quad bel(x_t) = p(x_t | z_t(a))$$



durch **geeignete Wahl** der Aktion  $a$

## Active Perception for Robots: Example

### Initial scenario



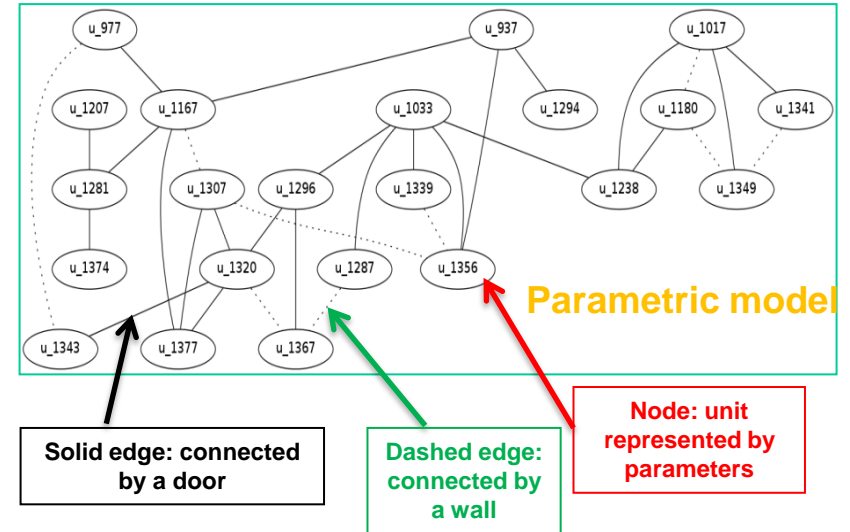


### Observations





# Results using weak context knowledge as prior






# Knowledge reasoning in MLNs

ratio \ size	small	big
small	room-like	corridor-like
big	hall-like	hall-like

predicate	explanation
$RoLi(u_p)$	Unit $u_p$ has a room-like geometry.
$CoLi(u_p)$	Unit $u_p$ has a corridor-like geometry.
$HaLi(u_p)$	Unit $u_p$ has a hall-like geometry.
$MulDoor(u_p)$	Unit $u_p$ has multiple doors.
$Adj(u_p, u_q)$	Unit $u_p$ and $u_q$ are adjacent.


## Evidence predicates

world  $W$



a)

detect  $R$  by wall dilation



b)

predicate	explanation
$Room(u_p)$	Unit $u_p$ has the type of room.
$Corr(u_p)$	Unit $u_p$ has the type of corridor.
$Hall(u_p)$	Unit $u_p$ has the type of hall.
$Other(u_p)$	Unit $u_p$ has the type of other.
$SaLe(u_p, u_q)$	Unit $u_p$ and $u_q$ have each a wall with the same length.

## Query predicates

basic features:

$$Adj(u_p, u_q) \rightarrow Adj(u_q, u_p)$$

$$SaLe(u_p, u_q) \rightarrow SaLe(u_q, u_p)$$

reasoning on type:

$$HaLi(u_p) \rightarrow Hall(u_p)$$

$$HaLi(u_p) \rightarrow \neg Room(u_p)$$

$$HaLi(u_p) \rightarrow \neg Corr(u_p)$$

$$HaLi(u_p) \rightarrow \neg Other(u_p)$$

$$RoLi(u_p) \rightarrow \neg Hall(u_p)$$

$$CoLi(u_p) \rightarrow \neg Hall(u_p)$$

$$RoLi(u_p) \wedge \neg MulDoor(u_p) \rightarrow Room(u_p)$$

$$RoLi(u_p) \wedge \neg MulDoor(u_p) \rightarrow \neg Corr(u_p)$$

$$RoLi(u_p) \wedge MulDoor(u_p) \rightarrow Other(u_p)$$

$$CoLi(u_p) \wedge \neg MulDoor(u_p) \rightarrow Other(u_p)$$

$$CoLi(u_p) \wedge MulDoor(u_p) \rightarrow Corr(u_p)$$

$$CoLi(u_p) \wedge MulDoor(u_p) \rightarrow \neg Room(u_p)$$

reasoning on  $SaLe$ :

$$\neg Adj(u_q, u_p) \rightarrow \neg SaLe(u_p, u_q)$$

$$Room(u_p) \wedge Room(u_q) \wedge Adj(u_p, u_q) \rightarrow SaLe(u_p, u_q)$$

$$Room(u_p) \wedge Hall(u_q) \wedge Adj(u_p, u_q) \rightarrow \neg SaLe(u_p, u_q)$$

$$Room(u_p) \wedge Corr(u_q) \wedge Adj(u_p, u_q) \rightarrow \neg SaLe(u_p, u_q)$$

$$Hall(u_p) \wedge Corr(u_q) \wedge Adj(u_p, u_q) \rightarrow \neg SaLe(u_p, u_q)$$

$$Other(u_p) \wedge Hall(u_q) \wedge Adj(u_p, u_q) \rightarrow \neg SaLe(u_p, u_q)$$



$$Other(u_p) \wedge Corr(u_q) \wedge Adj(u_p, u_q) \rightarrow \neg SaLe(u_p, u_q)$$

$$Other(u_p) \wedge Room(u_q) \wedge Adj(u_p, u_q) \rightarrow \neg SaLe(u_p, u_q)$$



## Logic rules





# Experimental results





false(0)=0.074, hidden(0)=0.406  
false(1)=0.036, hidden(1)=0.424  
false(2)=0.092, hidden(2)=0.384  
false(3)=0.102, hidden(3)=0.386  
false(4)=0.094, hidden(4)=0.400  
false(5)=0.130, hidden(5)=0.348  
false(6)=0.912, hidden(6)=0.466



false(0)=0.082, hidden(0)=0.428  
false(1)=0.044, hidden(1)=0.432  
false(2)=0.150, hidden(2)=0.816  
false(3)=0.110, hidden(3)=0.382  
false(4)=0.496, hidden(4)=0.478



false(0)=0.070, hidden(0)=0.416  
false(1)=0.036, hidden(1)=0.454  
false(2)=0.158, hidden(2)=0.384  
false(3)=0.110, hidden(3)=0.400  
false(4)=0.152, hidden(4)=0.374  
false(5)=0.074, hidden(5)=0.358



false(0)=0.096, hidden(0)=0.404  
false(1)=0.088, hidden(1)=0.406  
false(2)=0.136, hidden(2)=0.808  
false(3)=0.138, hidden(3)=0.386  
false(4)=0.492, hidden(4)=0.506  
false(5)=0.914, hidden(5)=0.460



# Wahrnehmung als probabilistischer

- Wahrnehmungsprozess immer fehlerbehaftet
  - Expliziter Umgang mit den Fehlern!
  - Bayes-Filter als Modell für Wahrnehmungsvorgang unter Unsicherheit
  - Aktive Informationsbeschaffung!
- Wichtig für autonome Systeme in unsicheren Umgebungen:  
**Fähigkeit „Erwartungen“ zu formulieren**
  - Grundvoraussetzung für stetiges Aktualisieren des Weltzustands auf Basis fehlerbehafteter Wahrnehmungen
  - Vermeidung von Haluzinationen



$$Bel(x_t) = \eta \underbrace{P(z_t | x_t)}_{\text{Korrektur/ Mess-Update}} \underbrace{\int P(x_t | u_t, x_{t-1}) Bel(x_{t-1}) dx_{t-1}}_{\text{Prädiktion / Zeit-Update}}$$

Korrektur/ Mess-Update

Prädiktion / Zeit-Update



# Fortgeschrittene Konzepte der Wahrnehmung für Robotersysteme

## Basisthemen

## Algorithmen- klassiker

- Sensortypen
- Lineare Algebra+Geometrie
- Segmentierung in Pointclouds
- Registrierung
- Grundlagen Bildverarbeitung
- Muster- und Objekterkennung
- Local Features

## Wahrnehmung als Prozess

## Umgang mit Unsicherheit




- Umgang mit Unsicherheiten / Probabilistik
- Zustandschätzung und Datenfusion
- Sequential Bayes und der Kalmanfilter
- Probabilistische Sensormodelle
- Grundlagen der Informationstheorie und aktive Wahrnehmung
- Offene Fragen

# Fortgeschrittene Konzepte der Wahrnehmung für Robotersysteme

## Was sollten Sie (mindestens) mitnehmen?

- Ein paar wichtige Basistechniken und grundlegende Zusammenhänge für den Fall, dass Sie selber ein Wahrnehmungsproblem lösen (w/s)ollen
  - Betrachten Sie das als Pointer in die Literatur. Sie werden dort noch viele relevante Ideen und Konzepte finden
- Wahrnehmung ist ein kognitiver Vorgang / Denkprozess
  - Geeignete Modelle, die die wahrzunehmende Welt beschreiben sind erforderlich
  - Der explizite Umgang mit Unsicherheit extrem wichtig für die Robustheit
  - Probabilistische Konzepte wie das Bayes-Filter liefern deshalb gute Denkmodelle für die Beschäftigung mit Wahrnehmungsthemen
    - vgl. Mining im „Big Data“

**EIN PAAR DENKANSTÖSSE ZUM  
ABSCHLUSS**



$$p(\mathbf{x}|\mathbf{z}) = \frac{p(\mathbf{z}|\mathbf{x}) p(\mathbf{x})}{p(\mathbf{z})} = \frac{p(\mathbf{z}|\mathbf{x}) p(\mathbf{x})}{\int p(\mathbf{z}|\mathbf{x}) p(\mathbf{x}) d\mathbf{x}}$$

**x** → unser **mentales „Bild“** von der Welt

**z** → unser **Eingangsdatenstrom**